

Politechnika Warszawska
WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Praca dyplomowa inżynierska

na kierunku Informatyka
w specjalności Sztuczna Inteligencja

Optymalizacja inferencji dyfuzyjnego modelu superrozdzielczości wideo
na kartach graficznych o ograniczonej pamięci

Daniel Machniak

Numer albumu 325190

promotor
prof. dr hab. inż. Przemysław Rokita

WARSZAWA 2026

Optymalizacja inferencji dyfuzyjnego modelu superrozdzielczości wideo na kartach graficznych o ograniczonej pamięci

Streszczenie

TODO: Napisać streszczenie w języku polskim.

Słowa kluczowe: superrozdzielczość wideo, modele dyfuzyjne, FlashVSR, kwantyzacja, mechanizmy uwagi, optymalizacja inferencji

Inference optimization of a diffusion-based video super-resolution model on memory-constrained GPUs

Abstract

TODO: Write the abstract in English.

Keywords: video super-resolution, diffusion models, FlashVSR, quantization, attention mechanisms, inference optimization

Spis treści

1 Wstęp	1
1.1 Motywacja i sformułowanie problemu	1
1.2 Cel i zakres pracy	1
1.3 Struktura pracy	2
2 Podstawy teoretyczne	3
2.1 Superrozdzielczość wideo	3
2.1.1 Sformułowanie problemu	3
2.1.2 Spójność czasowa	3
2.2 Modele dyfuzyjne	4
2.3 Transformer wizyjny	5
2.4 Transformer dyfuzyjny	5
2.5 Optymalizacje mechanizmu uwagi	6
2.5.1 FlashAttention	6
2.5.2 SageAttention	6
2.5.3 Block Sparse Attention	6
2.5.4 SpargeAttention	7
2.6 Kwantyzacja całkowitoliczbowa	7
2.6.1 Mechanizmy mapowania	7
2.6.2 Kwantyzacja wag (Weights)	8
2.6.3 Kwantyzacja aktywacji	8
2.7 Metryki oceny jakości obrazu i wideo	8
2.7.1 Metryki pełnoreferencyjne	8
2.7.2 Metryki bezreferencyjne	9
3 Przegląd istniejących rozwiązań	10
3.1 Metody konwolucyjne i rekurencyjne	10
3.2 Metody oparte na transformerach	10
3.3 Metody dyfuzyjne	10
3.4 Model FlashVSR	11
3.5 Podsumowanie i wyznaczenie luki badawczej	12
3.5.1 Porównanie i klasyfikacja metod VSR	12
3.5.2 Ograniczenia modelu FlashVSR	12
3.5.3 Sformułowanie problemu i celu pracy	13
4 Wybór rozwiązań do implementacji	14
4.1 Mechanizm uwagi	14
4.2 Kwantyzacja	14
4.3 Ograniczenie rozmiaru przetwarzanego fragmentu	15
4.4 Podsumowanie	15
5 Środowisko i projekt systemu	16
5.1 Platforma sprzętowa	16
5.2 Środowisko programistyczne	16
5.3 Architektura pakietu	16

5.4 Przepływ przetwarzania	17
5.5 Interfejsy systemu	17
5.6 Jakość kodu	18
6 Implementacja	19
7 Metodyka badań i testy	20
8 Wyniki i ich omówienie	21
9 Podsumowanie i wnioski	22
Bibliografia	23
Wykaz symboli i skrótów	25
Spis rysunków	25
Spis tabel	25
TODOs	26

1 Wstęp

1.1 Motywacja i sformułowanie problemu

Technologia superrozdzielczości wideo (ang. *Video Super-Resolution*, VSR) służy do rekonstrukcji sekwencji o wysokiej rozdzielczości na podstawie jej zdegradowanego odpowiednika. Wykorzystuje się ją w wielu praktycznych zastosowaniach, począwszy od rekonstrukcji archiwalnych nagrań i skalowania skompresowanych mediów na platformach streamingowych, aż po poprawę jakości nagrań z monitoringu i badań medycznych.

Podejścia wykorzystujące głębokie uczenie do VSR od dawna oparte są na architekturach splotowych i bazujących na Transformerach, trenowanych z wykorzystaniem funkcji straty opartej na rekonstrukcji pikselowej. Taka funkcja sprzyja zachowawczym wartościom pikseli, czego skutkiem jest powstawanie zbyt wygładzonych obrazów, pozbawionych detali. Wykorzystanie modeli dyfuzyjnych próbuje rozwiązać te problemy. Ponieważ są to metody generatywne, zamiast uśredniać możliwe rozwiązania, odtwarzają one prawdopodobne szczegóły. Przekłada się to na ostrzejsze i bardziej naturalne rezultaty. Poprawa ta ma jednak swój koszt, VSR oparte na dyfuzji jest wymagające pod względem obliczeniowym, pamięciowym oraz czasowym. Iteracyjny proces odszumiania i kwadratowa złożoność uwagi w odniesieniu do tokenów czasoprzestrzennych utrudnia praktyczne wykorzystanie.

Jednokrokowe modele uzyskiwane w wyniku destylacji wiedzy są częściową odpowiedzią na ten problem. Reprezentatywnym przykładem jest *FlashVSR* [1]. Twórcy modelu połączyli destylację do modelu jednokrokowego z blokowo-rzadką uwagą, aby zbliżyć się do przetwarzania w czasie rzeczywistym. Destylacja eliminuje koszt wielokrotnego odszumiania, ale nie redukuje narzutu pamięciowego w pojedynczej inferencji, który determinuje, czy model może zostać uruchomiony na danym urządzeniu.

Stwarza to istotną barierę, ponieważ dostępne modele, takie jak *FlashVSR*, zakładają wykorzystanie akceleratorów klasy serwerowej. Autorzy tego modelu wskazują, że szczytowe zużycie pamięci osiąga 11,13 GB przy 101 klatkach o rozdzielczości wyjściowej 768×1408 [1]. Oznacza to, że sekwencja wejściowa miała wymiary zaledwie 192×352 przy powiększeniu $\times 4$, czyli parametry znacząco odbiegające od rozdzielczości typowych nagrań. Konsumenckie karty graficzne oferują zazwyczaj od 8 do 12 GB pamięci VRAM; sprzęt referencyjny przyjęty w pracy, czyli NVIDIA RTX 3080, zapewnia 10 GB. Zapotrzebowanie na pamięć przekracza dostępny budżet nawet w tak korzystnym scenariuszu, a deficyt ten rośnie wraz ze wzrostem rozdzielczości wejściowej. Rodzi to pytanie, czy model tej klasy da się uruchomić w budżecie 10 GB VRAM i jakimi kompromisami w zakresie jakości rekonstrukcji oraz czasu inferencji się to wiąże.

1.2 Cel i zakres pracy

Celem pracy jest umożliwienie inferencji jednokrokowego, dyfuzyjnego modelu superrozdzielczości wideo na karcie graficznej wyposażonej w 10 GB pamięci VRAM, przy zachowaniu akceptowalnych jakości rekonstrukcji i czasu przetwarzania. Jako model bazowy przyjęto *FlashVSR* [1].

Realizacja tego celu wymagała refaktoryzacji kodu referencyjnej implementacji do postaci modularnego pakietu oraz zaimplementowania trzech konfigurowalnych technik redukujących wymagania sprzętowe: wymiennych wariantów mechanizmu uwagi, kwantyzacji, oraz kafelkowania przestrzennego i czasowego. Opracowano również metodykę pomiarową obejmującą czas inferencji, szczytowe zużycie pamięci i jakość rekonstrukcji. Umożliwiło to porównanie uzyskanych konfiguracji między sobą oraz z konfiguracją referencyjną.

Zakres pracy ogranicza się do fazy inferencji. Nie przeprowadzono treningu ani dostrajania, a we wszystkich eksperymentach wykorzystano publicznie udostępnione wagi. Wkład pracy ma charakter inżynieryjno-eksperymentalny i polega na adaptacji istniejącego modelu do środowiska o ograniczonych zasobach i zbadaniu zależności między jakością rekonstrukcji, czasem inferencji a zużyciem pamięci.

1.3 Struktura pracy

TODO: Opisać strukturę pracy.

2 Podstawy teoretyczne

2.1 Superrozdzielczość wideo

Superrozdzielczość wideo to zadanie z zakresu widzenia komputerowego, którego celem jest generowanie materiałów wideo o wysokiej rozdzielczości (ang. *high-resolution*, HR) i ulepszonej jakości wizualnej na podstawie wejściowych sekwencji o niskiej rozdzielczości (ang. *low-resolution*, LR). Podstawową różnicą między VSR a superrozdzielczością obrazów (ang. *Single Image Super-Resolution*, SISR) jest obecność w wideo dodatkowego wymiaru czasowego. SISR bazuje wyłącznie na informacji przestrzennej z pojedynczego obrazu, natomiast VSR wykorzystuje dodatkowo silne korelacje między kolejnymi klatkami. Bezpośrednie zastosowanie metod SISR do poszczególnych klatek wideo nie pozwala na uchwycenie tych zależności czasowych [2].

2.1.1 Sformułowanie problemu

Problem superrozdzielczości wideo jest zdefiniowany jako zadanie odwrotne, w którym dążymy do odzyskania sekwencji HR na podstawie obserwowanej sekwencji LR. Proces powstawania materiału LR jest zazwyczaj modelowany jako złożenie degradacji fizycznych i cyfrowych.

Ogólny model degradacji dla i -tej klatki wideo można zapisać jako funkcję zależną od klatki docelowej I_i^{HR} oraz jej sąsiedztwa czasowego [3]:

$$I_i^{\text{LR}} = \phi\left(I_i^{\text{HR}}, \{I_j^{\text{HR}}\}_{j=i-N}^{i+N}; \theta_\alpha\right) \quad (1)$$

gdzie I_i^{LR} oznacza obserwowaną klatkę o niskiej rozdzielczości, N oznacza promień czasowy (zakres sąsiednich klatek), a θ_α reprezentuje parametry procesu degradacji (np. szum, rozmycie).

Celem modelu VSR jest znalezienie funkcji odwzorowującej f_{VSR} , sparametryzowanej przez wagi $\theta_{f_{\text{VSR}}}$, która estymuje klatkę wysokiej rozdzielczości $\hat{I}_i^{\text{SR}}$ na podstawie sekwencji klatek wejściowych LR [3]:

$$\hat{I}_i^{\text{SR}} = f_{\text{VSR}}\left(I_i^{\text{LR}}, \{I_j^{\text{LR}}\}_{j=i-N}^{i+N}; \theta_{f_{\text{VSR}}}\right) \quad (2)$$

Powyższe klasyczne sformułowania zakładają uproszczone, deterministyczne zniekształcenia, które nie odzwierciedlają warunków rzeczywistych. W praktyce proces utraty jakości wymaga zaawansowanych modeli degradacji, które łączą losowe rozmycia, szum oraz zmianę rozmiaru i artefakty kompresji [4].

2.1.2 Spójność czasowa

Spójność czasowa w kontekście superrozdzielczości wideo polega na utrzymaniu ciągłości, płynności oraz braku zauważalnych zniekształceń i migotania między kolejnymi klatkami wygenerowanej sekwencji HR [2], [3]. Bezpośrednie zastosowanie metod SISR do poszczególnych klatek pomija zależności czasowe, co prowadzi do niestabilności detali i artefaktów wizualnych. W modelach głębokiego uczenia spójność tę realizuje się poprzez techniki wyrównywania klatek i kompensacji ruchu (ang. *motion estimation and motion compensation*, MEMC), konwolucje 3D, moduły rekurencyjne (RNN) propagujące kontekst czasowy oraz mechanizmy uwagi [2]. Choć metody te poprawiają jakość generowanych sekwencji, analiza wielu klatek znacznie zwiększa

złożoność obliczeniową i pamięciową, a w warunkach rzeczywistych stwarza ryzyko akumulacji i przenoszenia błędów między klatkami [4].

2.2 Modele dyfuzyjne

Modele dyfuzyjne (ang. *Denoising Diffusion Probabilistic Models*, DDPMs) to klasa modeli generatywnych wykorzystująca dwa podstawowe łańcuchy Markova: w przód (ang. *forward chain*), który stopniowo zniekształca dane poprzez dodawanie szumu, oraz w tył (ang. *reverse chain*), przekształcający szum z powrotem w ustrukturyzowane dane [5].

Proces w przód, nazywany również procesem dyfuzji, stopniowo degradowe oryginalne dane x_0 poprzez dodawanie szumu gaussowskiego w ciągu T kroków czasowych. W każdym kroku przejście nakłada szum zgodnie z określonym harmonogramem wariancji β_t , co matematycznie opisuje rozkład warunkowy [6]:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t \mathbf{I}) \quad (3)$$

Intuicyjnie proces ten, stopniowo wprowadzając szum, doprowadza do całkowitej utraty pierwotnej struktury danych, przekształcając ich rozkład w standardowy rozkład Gaussa. Istotną zaletą tego procesu jest możliwość wyrażenia go w postaci zamkniętej. Oznacza to, że można bezpośrednio wygenerować próbkę x_t w dowolnym kroku czasowym t , bez konieczności obliczania kroków pośrednich [5], [6].

Proces w tył (odszumianie) jest procesem odwrotnym, odpowiedzialnym za generowanie nowych danych. Rozpoczyna się od próbkowania losowego wektora szumu ze standardowego rozkładu Gaussa, a następnie stopniowego usuwania szumu poprzez realizację wyuczonego łańcucha Markova wstecz od kroku T do 1. Ponieważ proces w przód w każdym kroku wprowadza niewielkie ilości szumu, przejścia odwrotne również można modelować jako warunkowe rozkłady Gaussa. Te wyuczalne przejścia są parametryzowane przez głębokie sieci neuronowe i opisywane równaniem [5], [6]:

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t)) \quad (4)$$

gdzie sieć estymuje wartość średnią oraz wariancję w celu odtworzenia obrazu o mniejszym poziomie szumu. W praktyce, zamiast bezpośredniej estymacji parametrów rozkładu μ_{θ} oraz Σ_{θ} , sieć jest najczęściej trenowana do przewidywania szumu gaussowskiego, który został dodany do czystych danych w kroku t .

W klasycznych modelach dyfuzyjnych zmienne pośrednie mają ten sam wymiar co dane wejściowe. Aby zniwelować wynikające z tego ograniczenia obliczeniowe, stosuje się dyfuzję w przestrzeni ukrytej (ang. *Latent Diffusion Models*, LDMs) [5]. Podejście to opiera się na hipotezie rozmaitości (ang. *manifold hypothesis*), zakładającej, że naturalne sygnały leżą na podprzestrzeniach o znacznie niższym wymiarze. Modele LDM wykorzystują autoenkoder do skompresowania wysokowymiarowych danych w ciągłą reprezentację ukrytą (ang. *latent space*). Właściwy proces dyfuzji odbywa się wyłącznie w tej skompresowanej przestrzeni, a dekodery mapuje odszumiony wektor ukryty z powrotem do przestrzeni pikseli, co znacząco redukuje zapotrzebowanie na pamięć i moc obliczeniową [5].

2.3 Transformer wizyjny

Architektura Transformer znalazła skuteczne zastosowanie również w wizji komputerowej jako Transformer wizyjny (ang. *Vision Transformer*, ViT) [7]. Zamiast wykorzystywać filtry splotowe, ViT dzieli obraz na łatki (**patches**) i traktuje je analogicznie do tokenów słów w modelach NLP.

Dane wejściowe $x \in \mathbb{R}^{H \times W \times C}$ są dzielone na sekwencję łat $x \in \mathbb{R}^{N \times (P^2 \cdot C)}$, gdzie (H, W) to rozdzielczość obrazu, C to liczba kanałów, P to rozmiar łaty, a $N = \frac{HW}{P^2}$ to wyjściowa liczba łat stanowiąca długość sekwencji wejściowej dla Transformera. Następnie każda łatka jest rzutowana liniowo do wymiaru ukrytego D , a do uzyskanych wektorów dodawane są wyuczalne osadzenia pozycyjne w celu zachowania informacji o strukturze przestrzennej. Tak przygotowane osadzenia trafiają do enkodera Transformera. Po przetworzeniu sekwencji konieczne jest jej ponowne odwzorowanie do przestrzeni pikseli. Zazwyczaj wykorzystuje się do tego konwolucję podpikselową (ang. *pixel shuffle*). Metoda ta reorganizuje elementy wyjściowych map cech poprzez przekształcenie głębokości w wymiary przestrzenne (ang. *depth-to-space*), pozwalając na odtworzenie wysokiej rozdzielczości bez wprowadzania dodatkowych trenowalnych parametrów [2].

Adaptacja ViT do superrozdzielczości wideo polega na rozszerzeniu podziału na płyty do przestrzeni trójwymiarowej, co umożliwia jednocześnie modelowanie relacji przestrzennych i czasowych. Poprzez zastosowanie mechanizmu samouwagi (ang. *Self-Attention*), modele VSR dynamicznie szacują istotność różnych klatek wewnątrz analizowanego okna czasowego, co pozwala wyselekcjonować najbardziej informatywne fragmenty z sąsiednich klatek i wykorzystać je do precyzyjnej rekonstrukcji detali [2].

2.4 Transformer dyfuzyjny

Połączenie zalet modeli dyfuzyjnych w przestrzeni ukrytej (LDM) oraz skalowalności architektury ViT doprowadziło do powstania transformerów dyfuzyjnych (ang. *Diffusion Transformer*, DiT) [8]. W przeciwieństwie do klasycznych modeli LDM, które wykorzystują splotowe sieci typu U-Net jako kręgosłup (ang. *backbone*) procesu odszumiania, architektura DiT zastępuje je enkoderem opartym na Transformerze.

Przetwarzanie w DiT rozpoczyna się od skompresowania obrazu do przestrzeni ukrytej za pomocą zamrożonego, wstępnie wytrenowanego autoenkodera (np. VAE). Na tak uzyskanej reprezentacji z_0 aplikowany jest proces dyfuzji, a zaszumiony wektor ukryty z_t dzielony jest na siatkę płyt. Następnie są one rzutowane liniowo na sekwencję tokenów i wzbogacane o sinusoidalne osadzenia pozycyjne. Kluczową innowacją architektury DiT jest sposób wstrzykiwania informacji warunkujących, takich jak krok czasowy t czy etykieta klasy c . Do tego celu wykorzystuje się zmodyfikowane bloki z adaptacyjną normalizacją warstwową (ang. *adaptive layer normalization*, adaLN-Zero). Zamiast standardowej normalizacji, sieć regresuje parametry skali i przesunięcia (γ, β) oraz skalar przeskalowujący α bezpośrednio z sumy wektorów osadzeń warunków. Po przejściu przez bloki DiT, wyjściowa sekwencja tokenów jest dekodowana liniowo i reorganizowana do pierwotnego kształtu reprezentacji ukrytej, skąd dekodér przekształca ją z powrotem do przestrzeni pikseli [8].

Głównym wyzwaniem w adaptacji architektur DiT do zadań superrozdzielczości wideo jest potrzeba uwarunkowania procesu generatywnego nagraniem LR. W modelach VSR opartych na DiT (takich jak *FlashVSR*) sekwencja HR nie jest generowana z czystego szumu; zamiast tego do sterowania odtwarzaniem detali wykorzystuje się wideo LR. Wbudowywanie warunku realizuje się m.in. poprzez rzutowanie klatek LR za pomocą lekkiej warstwy konwolucyjnej (*Proj-In*) i dodanie tak uzyskanych cech do tokenów jako osadzenia warunkujące [1].

2.5 Optymalizacje mechanizmu uwagi

Standardowy mechanizm uwagi oparty na iloczynie skalarnym ze skalowaniem (*Scaled Dot-Product Attention*) stanowi fundament architektury Transformer. Odzworowuje on zapytania (Q), klucze (K) oraz wartości (V) na wektor wyjściowy zgodnie z zależnością [9]:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5)$$

gdzie d_k oznacza wymiarowość kluczy, a dzielenie przez $\sqrt{d_k}$ zapobiega zanikaniu gradientów dla dużych wartości iloczynu skalarnego. Mimo że operacja ta opiera się na wydajnych mnożeniach macierzowych, charakteryzuje się kwadratową złożonością obliczeniową i pamięciową $O(N^2)$ względem długości sekwencji N . Wynika to z konieczności bezpośredniego zapisywania pełnej, pośredniej macierzy uwagi w pamięci karty graficznej [10].

2.5.1 FlashAttention

FlashAttention [10] niweluje ograniczenia pamięciowe poprzez algorytm optymalizujący przepływ danych, nie wprowadzając przy tym żadnych aproksymacji. Zamiast zapisywać pośrednią macierz uwagi w wolniejszej pamięci HBM (ang. *High Bandwidth Memory*), algorytm stosuje technikę kafelkowania (ang. *tiling*). Bloki macierzy Q , K i V są ładowane do znacznie szybszej pamięci podręcznej SRAM na chipie GPU, gdzie stopniowo obliczana jest redukcja *softmax*, a do pamięci HBM zapisywany jest jedynie ostateczny wynik.

2.5.2 SageAttention

SageAttention [11] przyspiesza inferencję, wykorzystując kwantyzację. Ponieważ operacje mnożenia macierzy w formacie INT8 na nowoczesnych jednostkach GPU są znacznie szybsze niż w formatach FP16 czy FP8, metoda kwantyzuje macierze Q i K do formatu INT8, pozostawiając macierze P (macierz wag uwagi po operacji *softmax*) oraz V w formacie FP16. Aby zapobiec utracie dokładności wynikającej z ograniczonego zakresu liczbowego, wprowadzono technikę wygładzania usuwającą wartości odstające z macierzy K .

Wersja *SageAttention2* [12] wprowadza jeszcze szybszą kwantyzację INT4 dla Q i K oraz kwantyzację FP8 dla P i V , łącząc to z kompleksowym wygładzaniem wartości odstających dla obu macierzy Q i K .

2.5.3 Block Sparse Attention

Block Sparse Attention to metoda aproksymacyjna redukująca złożoność poprzez odrzucanie nadmiarowych obliczeń. Zamiast pełnych interakcji uwaga ograniczana jest wyłącznie do wybranych, niezerowych bloków.

Przykładowo, w modelach takich jak *FlashVSR*, algorytm najpierw wyznacza przybliżoną mapę uwagi poprzez uśrednianie (ang. *average pooling*) cech kluczy i wartości w celu uzyskania reprezentacji blokowych. Następnie wybierana jest grupa k najbardziej istotnych par bloków (ang. *top-k*), a pełny mechanizm uwagi aplikowany jest wyłącznie do tych obszarów. Integracja tej metody z *FlashAttention* pozwala obniżyć złożoność operacji wejścia/wyjścia proporcjonalnie do współczynnika rzadkości [10].

2.5.4 SpargeAttention

SparseAttention [13] to uniwersalna metoda niewymagająca ponownego trenowania, która łączy cechy uwagi rzadkiej oraz kwantyzacji w celu przyspieszenia predykcji bez utraty jakości modelu. Działając w oparciu o szkielet *SageAttention*, wykorzystuje dwuetapowy filtr do pomijania zbędnych mnożeń macierzowych. W pierwszym etapie bloki Q oraz K wykazujące wysokie podobieństwo są kompresowane do pojedynczych tokenów, co pozwala na szybsze i bardziej precyzyjne przewidywanie oraz maskowanie rzadkich obszarów na mapie uwagi. W drugim etapie algorytm *sparse warp online softmax* pomija obliczanie iloczynu PV , jeśli lokalna wartość maksymalna w danym bloku jest znacząco mniejsza od wartości maksymalnej w skali globalnej, skutecznie ignorując mało znaczące wartości.

2.6 Kwantyzacja całkowitoliczbowa

Kwantyzacja całkowitoliczbowa (ang. *Integer Quantization*) polega na konwersji wartości o wysokiej precyzji (np. FP32) na nisko-precyzyjne formaty całkowitoliczbowe (np. INT8), co przyspiesza inferencję poprzez wykorzystanie dedykowanych jednostek obliczeniowych i redukcję zapotrzebowania na pamięć. Proces ten opiera się na operacji kwantyzacji, czyli mapowaniu wartości rzeczywistych na całkowite, oraz dekwantyzacji, odpowiedzialnej za odtworzenie wartości przybliżonych [14].

2.6.1 Mechanizmy mapowania

Jednostajna kwantyzacja przekształca rzeczywiste wartości $x \in [\beta, \alpha]$ na b -bitowe reprezentacje całkowitoliczbowe x_q . Przekształcenie to opiera się na transformacji afinicznej (ang. *affine quantization*) $f(x) = s \cdot x + z$ lub jej szczególnym przypadku - transformacji skalowanej (ang. *scale quantization*) $f(x) = s \cdot x$ [14].

Kwantyzacja afiniczna mapuje zakres rzeczywisty na przedział ze znakiem $[-2^{b-1}, 2^{b-1} - 1]$ przy użyciu skali $s = \frac{2^b - 1}{\alpha - \beta}$ oraz całkowitoliczbowego punktu zerowego $z = -\text{round}(\beta \cdot s) - 2^{b-1}$, odpowiedzialnego za dokładne odwzorowanie wartości zero. Samą kwantyzację oraz dekwantyzację definiuje się wzorami:

$$x_q = \text{clip}(\text{round}(s \cdot x + z), -2^{b-1}, 2^{b-1} - 1), \quad \hat{x} = \frac{1}{s}(x_q - z) \quad (6)$$

Kwantyzacja skalowana (w wariancie symetrycznym) zakłada symetrię przedziału wejściowego $[-\alpha, \alpha]$ oraz zakresu bitowego wokół zera (dla INT8 jest to $[-127, 127]$, bez wartości -128). Przy skali $s = \frac{2^{b-1} - 1}{\alpha}$, operacje przyjmują postać:

$$x_q = \text{clip}(\text{round}(s \cdot x), -2^{b-1} + 1, 2^{b-1} - 1), \quad \hat{x} = \frac{1}{s}x_q \quad (7)$$

2.6.2 Kwantyzacja wag (Weights)

Ponieważ wagi podczas inferencji są statyczne, wyznaczanie ich parametrów kwantyzacji odbywa się w trybie offline. W tym celu stosuje się kwantyzację kanałową (ang. *per-channel*), która zachowuje dokładność modelu przy zróżnicowanych rozkładach cech pomiędzy kanałami. Zakres wartości α i β określa się zazwyczaj za pomocą kalibracji bazującej na maksymalnej wartości (*max calibration*), przy czym zdecydowanie preferuje się wariant symetryczny, ponieważ brak współczynnika z eliminuje dodatkowy narzut obliczeniowy podczas mnożenia macierzy [14].

2.6.3 Kwantyzacja aktywacji

Dynamiczna natura aktywacji wymusza odmienne podejście do wyznaczania zakresów mapowania. Aby umożliwić wydajne mnożenie macierzy, aktywacje kwantyzuje się na poziomie całego tensora (*per-tensor*). Ze względu na częstą obecność wartości odstających, zamiast kalibracji maksymalnej stosuje się kalibrację entropijną lub percentylową, co zapobiega spychaniu większości poprawnych wartości do zbyt wąskiego przedziału bitowego.

Połączenie symetrycznej kwantyzacji *per-channel* dla wag oraz kwantyzacji *per-tensor* z kalibracją entropijną lub percentylową dla aktywacji pozwala na prowadzenie obliczeń w pełni na arytmetyce INT8 przy dokładności zbliżonej do modelu bazowego FP32 [14].

2.7 Metryki oceny jakości obrazu i wideo

W celu przeprowadzenia kompleksowej ewaluacji jakości wygenerowanych sekwencji wideo zastosowano zestaw siedmiu metryk badawczych, obejmujący zarówno tradycyjne wskaźniki pełnoreferencyjne (ang. *Full-Reference*), jak i zaawansowane metryki percepcyjne oraz bezreferencyjne (ang. *No-Reference*).

2.7.1 Metryki pełnoreferencyjne

Metryki pełnoreferencyjne wymagają bezpośredniego porównania wygenerowanej klatki lub sekwencji ze źródłowym materiałem referencyjnym (ang. *Ground Truth*, GT).

Stosunek sygnału szczytowego do szumu (PSNR, ang. *Peak Signal-to-Noise Ratio*) [15] jest obiektywną metryką wyznaczającą stosunek maksymalnej możliwej wartości sygnału do błędu średniokwadratowego na poziomie poszczególnych pikseli. Mimo powszechnego stosowania w literaturze, metryka ta zakłada niezależność pikseli i wykazuje niską korelację z ludzką percepcją jakości wizualnej [2].

Wskaźnik podobieństwa strukturalnego (SSIM, ang. *Structural Similarity Index Measure*) [16] ocenia podobieństwo strukturalne między obrazami na podstawie analizy trzech komponentów: jasności (luminancji), kontrastu oraz informacji strukturalnej. Wartości metryki zawierają się w przedziale $[-1, 1]$, gdzie wartość 1 oznacza idealną zgodność. Choć SSIM lepiej odzwierciedla percepcję wzrokową niż PSNR, może dawać sprzeczne z intuicją wyniki w sytuacjach znacznych różnic kolorystycznych lub w bardzo ciemnych scenach [2].

Głęboka percepcyjna miara podobieństwa fragmentów obrazu (LPIPS, ang. *Learned Perceptual Image Patch Similarity*) [17] mierzy percepcyjną odmienność wizualną z wykorzystaniem cech wysokiego poziomu, wyekstrahowanych z głębokiej sieci neuronowej (np. VGG-16). Dzięki

wykorzystaniu reprezentacji wyuczonych na dużych zbiorach danych, LPIPS odzwierciedla subiektywne oceny ludzkie w stopniu znacznie wyższym niż klasyczne miary pikselowe [2].

2.7.2 Metryki bezreferencyjne

Metryki bezreferencyjne dokonują oceny jakości lub estetyki obrazu oraz wideo bez konieczności dostępu do materiału wzorcowego.

Naturalny ewaluator jakości obrazu (NIQE, ang. *Natural Image Quality Evaluator*) [18] ocenia stopień naturalności i zniekształceń obrazu poprzez ekstrakcję cech statystycznych (takich jak dane o jasności, kontraście czy krawędziach) i ich dopasowanie do wielowymiarowego rozkładu Gaussa. Metryka ta może jednak wykazywać niestabilność lub generować błędne wyniki w przypadku treści nietypowych, takich jak całkowicie czarne klatki, grafika komputerowa czy specyficzne tekstury o wysokiej częstotliwości.

Wieloskalowy transformer jakości obrazu (MUSIQ, ang. *Multi-scale Image Quality Transformer*) [19] jest bezreferencyjną metryką opartą na architekturze Transformer, dedykowaną do przetwarzania obrazów w ich natywnej rozdzielczości. Dzięki wieloskalowej analizie obrazu podzielonego na fragmenty, MUSIQ eliminuje potrzebę przeskalowywania lub przycinania wejścia, precyzyjnie wychytując zarówno globalną strukturę, jak i lokalne detale.

CLIPQA [20] wykorzystuje przestrzeń wizyjno-językową modeli wstępnie wytrenowanych CLIP do oceny zarówno aspektów technicznych, jak i właściwości estetycznych obrazu. Metryka ta nie wymaga ręcznie projektowanych cech ani dedykowanego uczenia pod konkretne zadanie, lecz wyznacza jakość poprzez pomiar dopasowania obrazu do przeciwstawnych promptów tekstowych (np. „*Good photo*” vs. „*Bad photo*”).

DOVER (ang. *Disentangled Objective Video Quality Evaluator*) [21] stanowi wyspecjalizowaną metrykę oceny jakości sekwencji wideo. Konstrukcja DOVER pozwala na predykcję subiektywnego doświadczenia jakości użytkownika w zróżnicowanych nagraniach wideo poprzez niezależne rozdzielenie analizy na aspekt estetyczny (jakość przestrzenna) oraz techniczny (spójność czasowa i płynność ruchu).

3 Przegląd istniejących rozwiązań

3.1 Metody konwolucyjne i rekurencyjne

Metody konwolucyjne realizują zadanie VSR poprzez podział wideo na nakładające się na siebie segmenty, co umożliwia równoległe przetwarzanie sąsiednich klatek w celu rekonstrukcji klatki docelowej. Reprezentatywny dla tej klasy model *EDVR* [22] wykorzystuje konwolucje deformowalne do adaptacyjnego dopasowania cech przy złożonym ruchu, oraz moduł TSA (*Temporal and Spatial Attention*) do fuzji informacji. Architektury konwolucyjne cechują się dużą stabilnością uczenia i odpornością na dynamiczne zmiany w scenie. Cierpią jednak na ograniczony zasięg kontekstu czasowego oraz wysoki narzut pamięciowy wynikający z wielokrotnego przetwarzania tych samych klatek. Ponadto niezależna rekonstrukcja kolejnych okien sprzyja powstawaniu artefaktów [2], [3].

Metody rekurencyjne (RNN) traktują wideo jako ciągły strumień danych i przekazują ukryty stan pamięci pomiędzy kolejnymi krokami czasowymi, co pozwala na modelowanie długoterminowych zależności. W modelu *BasicVSR* [23] zastosowano dwukierunkową propagację danych w czasie oraz moduł wyrównywania cech oparty na przepływie optycznym (ang. *optical flow*), który wyrównuje cechy przed przekazaniem ich do bloku rezydualnego. Pozwala to sieci na efektywne uwzględnianie informacji z całej sekwencji. Główną wadą dwukierunkowych metod rekurencyjnych pozostaje jednak wymóg znajomości całego wideo z góry oraz ryzyko stopniowego kumulowania i propagowania błędów rekonstrukcji [2], [3].

3.2 Metody oparte na transformerach

Transformery w VSR wykorzystują mechanizmy samouwagi (ang. *self-attention*) do dynamicznego ważenia i modelowania relacji czasowych wzdłuż całej sekwencji [2]. Przykładowo, model *VSRT* [24] posiada moduł STCSA (*Spatial-Temporal Convolutional Self-Attention*) do ekstrakcji lokalnych cech przestrzennych oraz dwukierunkową warstwę BOFF (*Bidirectional Optical Flow-Based Feed-Forward*), opartą na przepływie optycznym, do wyrównywania cech między klatkami. Alternatywne podejście reprezentuje *VRT* [25], który zamiast przetwarzać klipy sekwencyjnie, rekonstruuje je równoległe. Wykorzystuje on moduł TMSA (*Temporal Mutual Self-Attention*) do jednoczesnej estymacji ruchu, wyrównywania i fuzji cech.

Kluczową zaletą metod opartych na transformerach jest ich zdolność do bezstratnego wychwytywania długoterminowych zależności czasowych oraz możliwość równoległego przetwarzania klatek, co pozwala wyeliminować wąskie gardło rekurencji [25]. Głównym ograniczeniem pozostaje jednak bardzo wysoka złożoność obliczeniowa i ogromne zapotrzebowanie na pamięć w porównaniu z klasycznymi sieciami CNN [2].

3.3 Metody dyfuzyjne

Modele dyfuzyjne stanowią klasę rozwiązań generatywnych opartych na procesie iteracyjnego usuwania szumu z reprezentacji w przestrzeni utajonej. Integracja architektury transformerów z modelami dyfuzyjnymi pozwala na precyzyjne odtwarzanie złożonych tekstur oraz utrzymanie spójności czasowej między klatkami. Przykładem wielokrokowego podejścia jest model *Upscale-*

-A-Video [26], który stosuje lokalną i globalną strategię czasową oraz umożliwia sterowanie procesem rekonstrukcji za pomocą promptów tekstowych. Podstawowym ograniczeniem takich metod jest jednak konieczność wykonania kilkudziesięciu sekwencyjnych kroków inferencji, co generuje ogromny narzut obliczeniowy.

W odpowiedzi na ten problem rozwinięto metody jednokrokowe (ang. *one-step*), które skracają cały proces generatywny do pojedynczego przejścia sieci (ang. *forward pass*). Przykładowo, model DOVE [27] dostarcza wcześniej wyszkolony, zaawansowany model dyfuzyjny CogVideoX poprzez dwuetapową strategię uczenia *latent-pixel*, aby minimalizować różnice między ukrytymi reprezentacjami klatek przewidywanych i HR. Z kolei architektura SeedVR2 [28] wykorzystuje doszkalanie adversarialne (ang. *Diffusion Adversarial Post-Training*) oraz adaptacyjną samouwagę okienkową (ang. *adaptive window attention*), co pozwala na płynne przetwarzanie sekwencji wideo w wysokich rozdzielczościach bez powstawania artefaktów.

Podstawową zaletą metod jednokrokowych jest więc drastyczna redukcja czasu inferencji i zużycia zasobów poprzez zastąpienie wielokrotnych pętli odszumiania pojedynczym przejściem sieci. Odbywa się to jednak kosztem trudniejszego i mniej stabilnego treningu oraz większej podatności na artefakty przy złożonym ruchu.

3.4 Model FlashVSR

FlashVSR [1] to architektura przeznaczona do strumieniowego przetwarzania wideo w czasie rzeczywistym, wykorzystująca jednokrokowy model dyfuzyjny oparty na szkieletcie Wan 2.1-1.3B dostrojonym za pomocą metody LoRA. Aby wyeliminować opóźnienia i spadek wydajności, autorzy wprowadzili lekki moduł projekcji wejściowej (*Causal LR Projection-In*). Moduł ten grupuje po cztery klatki LR i poddaje je 8-krotnej kompresji przestrzennej za pomocą operacji *pixel shuffle*, a następnie 4-krotnej kompresji czasowej przy użyciu przyczynowych konwolucji 3D (*3D CausalConv*). Dzięki zastosowaniu pamięci podręcznej (ang. *causal cache*), cechy z poprzednich sekwencji są spójnie przenoszone i rzutowane przez perceptron wielowarstwowy bezpośrednio do przestrzeni utajonej transformera dyfuzyjnego.

Głównym rozwiązaniem problemu złożoności obliczeniowej standardowej samouwagi 3D jest zastosowanie blokowo-rzadkiego mechanizmu uwagi z ograniczeniem lokalnym (ang. *Locality-Constrained Sparse Attention*). FlashVSR wyznacza przybliżoną mapę uwagi poprzez uśrednianie reprezentacji kluczy i wartości, a pełne obliczenia wykonuje wyłącznie dla obszarów o najwyższych wynikach (ang. *top-k*). Dodatkowe nałożenie lokalnych okien przestrzennych ujednolica kodowanie pozycji między treningiem a wnioskowaniem, co umożliwia skalowanie modelu do bardzo wysokich rozdzielczości.

Zamiast dzielić długie wideo na nachodzące na siebie fragmenty FlashVSR przetwarza nagranie w sposób strumieniowy. Płynność i spójność klatek zapewnia pamięć *KV-cache* z mechanizmem okna przesuwanego. Pozwala ona przechowywać najważniejsze cechy obrazu z poprzednich kroków bez konieczności ponownego ich przeliczania.

Ostatnim kluczowym elementem architektury jest zastąpienie ciężkiego, standardowego dekodera 3D VAE autorskim, lekkim dekoderm warunkowym (ang. *Tiny Conditional Decoder*). Zapewnia on około 7-krotne przyspieszenie etapu rekonstrukcji obrazu w przestrzeni pikseli w

porównaniu z oryginalnym dekodery sieci Wan, nie powodując przy tym widocznej utraty jakości wizualnej.

3.5 Podsumowanie i wyznaczenie luki badawczej

3.5.1 Porównanie i klasyfikacja metod VSR

Dotychczasowy rozwój metod VSR pokazuje wyraźną ewolucję od szybkich, lecz ograniczonych jakościowo modeli konwolucyjnych i rekurencyjnych, przez dokładniejsze architektury oparte na transformerach, aż po generatywne modele dyfuzyjne. Każda z tych klas rozwiązań charakteryzuje się odmiennym kompromisem pomiędzy jakością generowanego obrazu, wydajnością a zapotrzebowaniem na zasoby sprzętowe.

Metody klasyczne (CNN/RNN) oferują najwyższą szybkość i niskie zużycie pamięci, jednak mają tendencję do generowania rozmytych tekstur. Transformery skutecznie modelują długoterminowe zależności czasowe, ale ich złożoność obliczeniowa rośnie kwadratowo wraz z długością sekwencji. Wielokrokowe modele dyfuzyjne zapewniają najwyższy fotorealizm, lecz konieczność wykonywania kilkudziesięciu iteracji pętli odsumowania uniemożliwia ich zastosowanie w trybie interaktywnym.

Architektura *FlashVSR* przełamuje to ograniczenie poprzez sprowadzenie procesu dyfuzji do jednego kroku inferencji oraz wprowadzenie mechanizmów strumieniowych i dedykowanego dekodera. Jakościowe zestawienie cech poszczególnych klas metod przedstawiono w [tabeli 1](#).

Tabela 1. Porównanie klas metod superrozdzielczości wideo pod względem kosztu obliczeniowego, zapotrzebowania na pamięć i jakości rekonstrukcji

Klasa metod (reprezentant)	Czas inferencji	Zużycie pamięci	Jakość rekonstrukcji*	Główne ograniczenie
Konwolucyjne - EDVR [22]	bardzo krótki	umiarkowane, rośnie z $H \cdot W$ i szerokością okna	wysoka wierność, niska jakość percepcyjna - wygładzone tekstury	wąski kontekst czasowy, redundantne przetwarzanie okien
Rekurencyjne - BasicVSR [23]	bardzo krótki	umiarkowane, stan ukryty utrzymywany przez cały klip	wysoka wierność, percepcyjnie średnia	wymaga całego nagrania z góry, akumulacja błędów
Transformerowe - VRT [25] , VSRT [24]	średni	wysokie, kwadratowe z długością sekwencji	najwyższa wierność, percepcyjnie średnia	złożoność $O(N^2)$ samouagi
Dyfuzyjne wielokrokowe - Upscale-A-Video [26]	bardzo długi	umiarkowane, bufor reużywany między krokami	niższa wierność, wysoka jakość percepcyjna	dziesiątki sekwencyjnych przejść sieci
Dyfuzyjne jednokrokowe - FlashVSR [1] , DOVE [27] , SeedVR2 [28]	krótki, jedno przejście	wysokie, wagi + KV-cache + aktywacje jednocześnie	niższa wierność, wysoka jakość percepcyjna	wysoki próg wejścia pamięci, niezależny od długości nagrania

* Wierność mierzona metrykami pełnreferencyjnymi (PSNR, SSIM), jakość percepcyjna - metrykami LPIPS oraz bezreferencyjnymi.

3.5.2 Ograniczenia modelu FlashVSR

Oryginalne wdrożenie tego modelu wykazuje ogromne zapotrzebowanie na pamięć karty graficznej. Wyniki wydajnościowe zaprezentowane przez autorów architektury uzyskano na

akceleratorze NVIDIA A100 z 80 GB VRAM. W domyślnej precyzji FP16/BF16 rozmiar wag modelu w połączeniu z buforem KV-cache oraz alokacją pamięci na aktywacje warstw samouwagi sprawia, że próba uruchomienia bazowej wersji *FlashVSR* na powszechnie dostępnych, konsumenckich kartach graficznych (np. z 10 GB VRAM) kończy się przepełnieniem pamięci.

3.5.3 Sformułowanie problemu i celu pracy

Głównym problemem jest więc brak możliwości bezpośredniego uruchomienia jednokrokowego modelu *FlashVSR* na sprzęcie o ograniczonych zasobach.

Celem niniejszej pracy jest zaprojektowanie, zrealizowanie i przeanalizowanie zoptymalizowanego potoku inferencji dla modelu *FlashVSR*. Wykorzystano w nim techniki takie jak kwantyzacja wag i aktywacji, zoptymalizowane mechanizmy uwagi oraz podział przestrzenno-czasowy, aby umożliwić stabilną i wydajną pracę modelu w reżimie 10 GB VRAM przy minimalnej utracie jakości wyjściowego obrazu.

4 Wybór rozwiązań do implementacji

Analiza z rozdziału 3 wykazała, że przeszkodą w uruchomieniu modelu *FlashVSR* na karcie konsumenckiej nie jest liczba kroków odsumiania, lecz szczytowe zapotrzebowanie na pamięć w obrębie pojedynczej inferencji. Wybór technik mających je obniżyć oparto na pięciu kryteriach: działanie wyłącznie na etapie inferencji, bez treningu, dostrajania i kalibracji na dodatkowym zbiorze; wsparcie w architekturze Ampere, stanowiącej platformę docelową; brak konieczności odzyskiwania utraconej jakości przez ponowne uczenie; możliwość porównania konfiguracji w jednolitym środowisku pomiarowym; oraz dostępność w postaci biblioteki o ustabilizowanym interfejsie. Na tej podstawie wybrano trzy osie optymalizacji: mechanizm uwagi, kwantyzację oraz ograniczenie rozmiaru przetwarzanego fragmentu.

4.1 Mechanizm uwagi

Blokowo-rzadki mechanizm uwagi stosowany w *FlashVSR* składa się z dwóch koncepcyjnie niezależnych elementów: jądra realizującego uwagę gęstą w obrębie okien lokalnych oraz metody selekcji istotnych par bloków w uwadze międzyokiennej. Ich rozdzielenie w warstwie Umożliwiło zbadać wpływ każdego z nich.

Jako referencyjne metodę dla gęstej uwagi przyjęto *FlashAttention* [10], stosowaną w oryginalnej implementacji, w której redukcja zużycia pamięci wynika wyłącznie z optymalizacji przepływu danych. Wariantem alternatywnym jest *SageAttention* [11], który nie wymaga ponownego trenowania, działa na poziomie pojedynczego wywołania mechanizmu uwagi, a wykorzystywany przez nią format INT8 jest wspierany przez architekturę Ampere.

Wariantem odniesienia dla selekcji rzadkiej jest uwaga blokowo-rzadka autorów *FlashVSR* [1]. Jako alternatywę wybrano *SparseAttention* [13], która realizuje to samo zadanie w sposób adaptacyjny, również nie wymaga trenowania, a działając w oparciu o szkielet *SageAttention* daje się z nią łączyć bez konfliktów implementacyjnych.

Parametry sterujące stopniem rzadkości (udział wybieranych par bloków, długość pamięci podręcznej kluczy i wartości oraz zasięg okna lokalnego) pozostawiono na wartościach przyjętych przez autorów modelu.

4.2 Kwantyzacja

Przyjęto format INT8. Formatu FP8 nie rozważano, ponieważ architektura Ampere go nie wspiera. Odrzucono również formaty czterobitowe, takie jak NF4 czy GGUF, ponieważ są rozwijane przede wszystkim pod kątem modeli językowych. Dla INT8 architektura Ampere udostępnia dedykowane jednostki tensorowe, a literatura raportuje dokładność zbliżoną do modelu bazowego przy odpowiednim doborze mechanizmu mapowania [14].

Do realizacji wybrano bibliotekę torchao, która działa przez podmianę tensorów wag na wyspecjalizowane podtypy, nie wymagając modyfikacji definicji modelu ani eksportu do reprezentacji pośredniej. Kwantyzację można więc włączyć jako opcjonalny krok inicjalizacji potoku.

Kwantyzacji poddano wyłącznie transformer dyfuzyjny, odpowiadający za większość parametrów modelu i wywoływany dla każdego fragmentu. Lekkiego dekodera warunkowego nie objęto zakresem pracy.

4.3 Ograniczenie rozmiaru przetwarzanego fragmentu

Zapotrzebowanie na pamięć w obrębie pojedynczego wywołania modelu zależy od liczby tokenów czasoprzestrzennych, a więc od rozdzielczości przetwarzanego fragmentu. Podział klatki na kafle przetwarzane kolejno sprawia, że szczytowe zużycie pamięci przestaje zależeć od rozdzielczości nagrania wejściowego, a zaczyna zależeć wyłącznie od rozmiaru kafla.

Kosztem jest redundancja obliczeń w obszarze zakładki oraz ryzyko widocznych nieciągłości na granicach kafli, rekonstruowanych niezależnie i bez dostępu do kontekstu sąsiadów. Przyjęto zatem przetwarzanie z zakładką i łączenie kafli maską o liniowo narastających wagach we wspólnym obszarze.

Analogiczny mechanizm zastosowano w wymiarze czasowym. *FlashVSR* przetwarza nagranie strumieniowo, a pamięć podręczna kluczy i wartości z oknem przesuwным ogranicza narastanie stanu, jednak bufor wejściowy i wyjściowy długich nagrań pozostają kosztowne pamięciowo. Sekwencję dzielono więc na segmenty o ustalonej długości, łączone z zakładką przez liniowe mieszanie klatek.

4.4 Podsumowanie

Wybrane techniki zestawiono w tabeli 2. Każda jest przełączalna w czasie działania, co pozwala badać zarówno pojedyncze rozwiązania, jak i ich kombinacje w jednolitym środowisku pomiarowym.

Tabela 2. Zestawienie technik wybranych do implementacji

Oś optymalizacji	Wariant odniesienia	Warianty alternatywne	Oczekiwany efekt
Jądro uwagi gęstej	FlashAttention [10]	SageAttention [11]	skrócenie czasu inferencji
Selekcja rzadka	uwaga blokowo-rzadka [1]	SparseAttention [13]	skrócenie czasu inferencji
Kwantyzacja	brak (bfloat16)	INT8 wag; INT8 wag i aktywacji	redukcja zużycia pamięci
Kafelkowanie przestrzenne	wyłączone	rozmiar kafla i zakładka jako parametry	uniezależnienie szczytu pamięci od rozdzielczości wejścia
Kafelkowanie czasowe	wyłączone	długość segmentu i zakładka jako parametry	ograniczenie zużycia pamięci dla długich nagrań

5 Środowisko i projekt systemu

5.1 Platforma sprzętowa

Platformą docelową jest karta NVIDIA GeForce RTX 3080 wyposażona w 10 GB pamięci VRAM, oparta na architekturze Ampere (compute capability 8.6). Reprezentuje ona segment kart konsumenckich, dla których zapotrzebowanie modelu FlashVSR przekracza dostępny budżet pamięci. Architektura Ampere udostępnia jednostki tensorowe operujące na formacie INT8, natomiast nie wspiera formatu FP8.

Część obliczeń wykonano na akceleratorze NVIDIA A100, ze względu na czas potrzebny na przetworzenie zbiorów testowych. Uruchomiono na nim również konfigurację referencyjną, bez kafelkowania przestrzennego, której zapotrzebowanie na pamięć przekracza budżet karty docelowej. Pomiary czasu inferencji, zużycia pamięci oraz metryki jakości wyznaczano na RTX 3080, ponieważ wyniki czasowe zależą od architektury karty i nie przenoszą się między platformami.

5.2 Środowisko programistyczne

System zaimplementowano w języku Python w wersji 3.11, z wykorzystaniem biblioteki PyTorch 2.10 skompilowanej dla CUDA 12.8. Do zarządzania zależnościami wykorzystano narzędzie `uv`, które zapisuje pełny stan środowiska w pliku blokującym wersje. Zapewnia to odtwarzalność instalacji, istotną przy tak dużej liczbie komponentów wymagających kompilacji ze źródeł.

Trzy biblioteki realizujące warianty mechanizmu uwagi - `block_sparse_attn`, `sageattention` oraz `spas_sage_attn` - instalowane są bezpośrednio z repozytoriów źródłowych i wymagają kompilacji jąder CUDA. Ich instalacja wymagała ustawienia zmiennych środowiskowych określających docelowe architektury GPU oraz wskazania kompilatora w wersji zgodnej z wymaganiami narzędzia `nvcc`. Proces ten zautomatyzowano skryptem powłoki. Pozostałe istotne zależności to `torchao` w wersji 0.16 (kwantyzacja), `torchcodec` i `av` (dekodowanie i kodowanie materiału wideo) oraz `pyiqa` (metryki jakości obrazu).

Osobnym problemem okazała się metryka DOVER, której implementacja referencyjna wymaga biblioteki PyTorch w wersji sprzed 2.0. Wersja ta jest niezgodna z pozostałymi komponentami systemu. Metrykę tę uruchamiano zatem w wydzielonym środowisku wirtualnym, na materiale wideo zapisanym wcześniej przez główny potok. Wyniki obu środowisk łączono na etapie agregacji.

5.3 Architektura pakietu

Implementacja referencyjna modelu FlashVSR ma postać zbioru skryptów, w których konfiguracja jest zapisana na stałe w kodzie, co uniemożliwia wygodne porównywanie wariantów. Kod zrefaktoryzowano zatem do postaci pakietu o wyraźnie rozdzielonych warstwach odpowiedzialności.

Warstwa `config` zawiera struktury opisujące konfigurację przetwarzania: tryb uwagi, tryb kwantyzacji, parametry kafelkowania przestrzennego i czasowego oraz parametry wejścia i wyjścia. Warstwa `models` obejmuje komponenty modelu: transformer dyfuzyjny, autoenkoder

oraz lekki dekodery warunkowy. Warstwa `pipelines` zawiera właściwy potok inferencji, warstwa `processing` odpowiada za jego inicjalizację i orkiestrację przetwarzania nagrania, a warstwa `utils` gromadzi funkcje pomocnicze obliczające podział na kafle, maski mieszania i wymagane wymiary danych.

Poza rdzeniem pakietu wydzielono cztery moduły pomocnicze: `benchmarks` z narzędziami pomiarowymi, `scripts` ze skryptami przetwarzania wsadowego i przygotowania danych, `app` z aplikacją pokazową oraz `tests` z testami jednostkowymi.

Istotnym założeniem projektowym jest oddzielenie budowy potoku od jego wykonania. Inicjalizacja obejmuje wczytanie wag, wybór wariantów uwagi oraz ewentualną kwantyzację, jest więc kosztowna czasowo i pamięciowo. Zbudowany potok może natomiast przetworzyć wiele nagrań bez ponownej inicjalizacji. Rozdzielenie to ma bezpośredni wpływ na metodykę pomiarową, ponieważ pozwala oddzielić jednorazowy koszt przygotowania modelu od kosztu właściwej inferencji.

5.4 Przepływ przetwarzania

Przetwarzanie nagrania przebiega w kilku etapach. Materiał wejściowy jest dekodowany, a liczba klatek dopełniana do wartości wymaganej przez model. Wymóg ten wynika z czasowej kompresji stosowanej przez autoenkoder. Następnie sekwencja dzielona jest na segmenty czasowe, a każdy segment na kafle przestrzenne. Kafle przetwarzane są kolejno przez potok inferencji, a ich wyniki łączone maską o liniowo narastających wagach w obszarze zakładki. Ostatnim etapem jest złożenie klatek wyjściowych i zapis materiału.

Kluczową decyzją projektową jest utrzymywanie płótna wyjściowego w pamięci operacyjnej, a nie w pamięci karty graficznej. Na karcie jednocześnie znajdują się wyłącznie wagi modelu, pamięć podręczna kluczy i wartości oraz aktywacje jednego kafła. Dzięki temu szczytowe zużycie pamięci karty zależy od rozmiaru kafła, a nie od rozdzielczości nagrania wejściowego.

5.5 Interfejsy systemu

Rdzeń systemu udostępniono przez trzy niezależne punkty wejścia, korzystające z tej samej implementacji potoku.

Pierwszym jest uruchomienie z wiersza poleceń, przeznaczone do przetwarzania pojedynczego nagrania. Drugim jest skrypt przetwarzania wsadowego, stosowany przy generowaniu wyników dla całych zbiorów testowych. Trzecim jest aplikacja pokazowa, złożona z usługi sieciowej zbudowanej w oparciu o bibliotekę FastAPI oraz interfejsu przeglądarkowego wykorzystującego bibliotekę Gradio.

Usługa sieciowa przyjmuje zlecenia przetwarzania wraz z pełną konfiguracją i obsługuje je asynchronicznie. Zlecenia trafiają do kolejki, z której pobiera je pojedynczy proces roboczy. Rozwiązanie takie jest konieczne, ponieważ równoległe przetwarzanie wielu nagrań przekroczyłoby budżet pamięci karty. Proces utrzymuje zbudowany potok między kolejnymi zleceniami i odtwarza go jedynie wtedy, gdy zmieni się konfiguracja uwagi lub kwantyzacji. Klient może sprawdzać stan zlecenia i pobrać wynik po zakończeniu przetwarzania.

5.6 Jakość kodu

Moduły pomocnicze odpowiedzialne za wyznaczanie podziału na kafle, generowanie masek mieszania oraz obliczanie wymaganych wymiarów danych objęto testami jednostkowymi z wykorzystaniem biblioteki `pytest`. Są to funkcje obliczeniowe, których poprawność decyduje o braku artefaktów w materiale wyjściowym, a jednocześnie dające się testować bez dostępu do karty graficznej. Statyczną analizę kodu i jego formatowanie realizuje narzędzie `ruff`.

6 Implementacja

7 Metodyka badań i testy

8 Wyniki i ich omówienie

9 Podsumowanie i wnioski

Bibliografia

- [1] J. Zhuang *et al.*, „FlashVSR: Towards Real-Time Diffusion-Based Streaming Video Super-Resolution”, *ArXiv*, 2025.
- [2] A. A. Baniya, T.-K. Lee, P. W. Eklund, i S. Aryal, „A Survey of Deep Learning Video Super-Resolution”, *IEEE Transactions on Emerging Topics in Computational Intelligence*, t. 8, nr 4, s. 2655–2676, sie. 2024, doi: [10.1109/tetci.2024.3398015](https://doi.org/10.1109/tetci.2024.3398015).
- [3] H. Liu *et al.*, „Video Super Resolution Based on Deep Learning: A Comprehensive Survey”. [Online]. Dostępne na: <https://arxiv.org/abs/2007.12928>
- [4] K. C. K. Chan, S. Zhou, X. Xu, i C. C. Loy, „Investigating Tradeoffs in Real-World Video Super-Resolution”. [Online]. Dostępne na: <https://arxiv.org/abs/2111.12704>
- [5] L. Yang *et al.*, „Diffusion Models: A Comprehensive Survey of Methods and Applications”. [Online]. Dostępne na: <https://arxiv.org/abs/2209.00796>
- [6] J. Ho, A. Jain, i P. Abbeel, „Denoising Diffusion Probabilistic Models”. [Online]. Dostępne na: <https://arxiv.org/abs/2006.11239>
- [7] A. Dosovitskiy *et al.*, „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. [Online]. Dostępne na: <https://arxiv.org/abs/2010.11929>
- [8] W. Peebles i S. Xie, „Scalable Diffusion Models with Transformers”. [Online]. Dostępne na: <https://arxiv.org/abs/2212.09748>
- [9] A. Vaswani *et al.*, „Attention Is All You Need”. [Online]. Dostępne na: <https://arxiv.org/abs/1706.03762>
- [10] T. Dao, D. Y. Fu, S. Ermon, A. Rudra, i C. Ré, „FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness”. [Online]. Dostępne na: <https://arxiv.org/abs/2205.14135>
- [11] J. Zhang, J. Wei, H. Huang, P. Zhang, J. Zhu, i J. Chen, „SageAttention: Accurate 8-Bit Attention for Plug-and-play Inference Acceleration”. [Online]. Dostępne na: <https://arxiv.org/abs/2410.02367>
- [12] J. Zhang, H. Huang, P. Zhang, J. Wei, J. Zhu, i J. Chen, „SageAttention2: Efficient Attention with Thorough Outlier Smoothing and Per-thread INT4 Quantization”. [Online]. Dostępne na: <https://arxiv.org/abs/2411.10958>
- [13] J. Zhang *et al.*, „SpargAttention: Accurate and Training-free Sparse Attention Accelerating Any Model Inference”. [Online]. Dostępne na: <https://arxiv.org/abs/2502.18137>
- [14] H. Wu, P. Judd, X. Zhang, M. Isaev, i P. Micikevicius, „Integer Quantization for Deep Learning Inference: Principles and Empirical Evaluation”. [Online]. Dostępne na: <https://arxiv.org/abs/2004.09602>
- [15] F. A. Fardo, V. H. Conforto, F. C. de Oliveira, i P. S. Rodrigues, „A Formal Evaluation of PSNR as Quality Measurement Parameter for Image Segmentation Algorithms”. [Online]. Dostępne na: <https://arxiv.org/abs/1605.07116>

- [16] J. Nilsson i T. Akenine-Möller, „Understanding SSIM”. [Online]. Dostępne na: <https://arxiv.org/abs/2006.13846>
- [17] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, i O. Wang, „The Unreasonable Effectiveness of Deep Features as a Perceptual Metric”. [Online]. Dostępne na: <https://arxiv.org/abs/1801.03924>
- [18] A. Zvezdakova, D. Kulikov, D. Kondranin, i D. Vatolin, „Barriers towards no-reference metrics application to compressed video quality analysis: on the example of no-reference metric NIQE”. [Online]. Dostępne na: <https://arxiv.org/abs/1907.03842>
- [19] J. Ke, Q. Wang, Y. Wang, P. Milanfar, i F. Yang, „MUSIQ: Multi-scale Image Quality Transformer”. [Online]. Dostępne na: <https://arxiv.org/abs/2108.05997>
- [20] J. Wang, K. C. K. Chan, i C. C. Loy, „Exploring CLIP for Assessing the Look and Feel of Images”. [Online]. Dostępne na: <https://arxiv.org/abs/2207.12396>
- [21] H. Wu *et al.*, „Exploring Video Quality Assessment on User Generated Contents from Aesthetic and Technical Perspectives”. [Online]. Dostępne na: <https://arxiv.org/abs/2211.04894>
- [22] X. Wang, K. C. K. Chan, K. Yu, C. Dong, i C. C. Loy, „EDVR: Video Restoration with Enhanced Deformable Convolutional Networks”. [Online]. Dostępne na: <https://arxiv.org/abs/1905.02716>
- [23] K. C. K. Chan, X. Wang, K. Yu, C. Dong, i C. C. Loy, „BasicVSR: The Search for Essential Components in Video Super-Resolution and Beyond”. [Online]. Dostępne na: <https://arxiv.org/abs/2012.02181>
- [24] J. Cao, Y. Li, K. Zhang, i L. V. Gool, „Video Super-Resolution Transformer”. [Online]. Dostępne na: <https://arxiv.org/abs/2106.06847>
- [25] J. Liang *et al.*, „VRT: A Video Restoration Transformer”. [Online]. Dostępne na: <https://arxiv.org/abs/2201.12288>
- [26] S. Zhou, P. Yang, J. Wang, Y. Luo, i C. C. Loy, „Upscale-A-Video: Temporal-Consistent Diffusion Model for Real-World Video Super-Resolution”. [Online]. Dostępne na: <https://arxiv.org/abs/2312.06640>
- [27] Z. Chen *et al.*, „DOVE: Efficient One-Step Diffusion Model for Real-World Video Super-Resolution”. [Online]. Dostępne na: <https://arxiv.org/abs/2505.16239>
- [28] J. Wang *et al.*, „SeedVR2: One-Step Video Restoration via Diffusion Adversarial Post-Training”. [Online]. Dostępne na: <https://arxiv.org/abs/2506.05301>

Wykaz symboli i skrótów

GOAT – greatest of all time

KDE Community: An international team developing and distributing Open Source software.

OIDC – **OpenID Connect**: OpenID is an open standard and decentralized authentication protocol promoted by the non-profit [OpenID Foundation](#).

WUT – Warsaw University of Technology

Spis rysunków

Spis tabel

Tabela 1	Porównanie klas metod superrozdzielczości wideo pod względem kosztu obliczeniowego, zapotrzebowania na pamięć i jakości rekonstrukcji	12
Tabela 2	Zestawienie technik wybranych do implementacji	15

TODOs

□ TODO: Napisać streszczenie w języku polskim.	2
□ TODO: Write the abstract in English.	3
□ TODO: Opisać strukturę pracy.	7