

Politechnika Warszawska
WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Praca dyplomowa inżynierska

na kierunku Informatyka
w specjalności Sztuczna Inteligencja

Optymalizacja inferencji dyfuzyjnego modelu superrozdzielczości wideo
na kartach graficznych o ograniczonej pamięci

Daniel Machniak

Numer albumu 325190

promotor
prof. dr hab. inż. Przemysław Rokita

WARSZAWA 2026

Optymalizacja inferencji dyfuzyjnego modelu superrozdzielczości wideo na kartach graficznych o ograniczonej pamięci

Streszczenie

TODO: Napisać streszczenie w języku polskim.

Słowa kluczowe: superrozdzielczość wideo, modele dyfuzyjne, FlashVSR, kwantyzacja, mechanizmy uwagi, optymalizacja inferencji

Inference optimization of a diffusion-based video super-resolution model on memory-constrained GPUs

Abstract

TODO: Write the abstract in English.

Keywords: video super-resolution, diffusion models, FlashVSR, quantization, attention mechanisms, inference optimization

Spis treści

1 Wstęp	1
1.1 Motywacja i sformułowanie problemu	1
1.2 Cel i zakres pracy	1
1.3 Struktura pracy	2
2 Podstawy teoretyczne	3
2.1 Superrozdzielczość wideo	3
2.1.1 Sformułowanie problemu	3
2.1.2 Spójność czasowa	3
2.2 Modele dyfuzyjne	4
2.3 Diffusion Transformer i mechanizm uwagi	4
2.4 Kwantyzacja sieci neuronowych	4
2.5 Kafelkowanie przestrzenne i czasowe	4
2.6 Metryki oceny jakości wideo	4
3 Przegląd istniejących rozwiązań	5
4 Wybór rozwiązań do implementacji	6
5 Narzędzia, środowisko i projekt systemu	7
6 Implementacja	8
7 Metodyka badań i testy	9
8 Wyniki i ich omówienie	10
9 Podsumowanie i wnioski	11
Bibliografia	12
Wykaz symboli i skrótów	13
Spis rysunków	13
Spis tabel	13
TODOs	14

1 Wstęp

1.1 Motywacja i sformułowanie problemu

Technologia superrozdzielczości wideo (ang. *Video Super-Resolution*, VSR) służy do rekonstrukcji sekwencji o wysokiej rozdzielczości na podstawie jej zdegradowanego odpowiednika. Wykorzystuje się ją w wielu praktycznych zastosowaniach, począwszy od rekonstrukcji archiwalnych nagrań i skalowania skompresowanych mediów na platformach streamingowych, aż po poprawę jakości nagrań z monitoringu i badań medycznych.

Podejścia wykorzystujące głębokie uczenie do VSR od dawna oparte są na architekturach splotowych i bazujących na Transformerach, trenowanych z wykorzystaniem funkcji straty opartej na rekonstrukcji pikselowej. Taka funkcja sprzyja zachowawczym wartościom pikseli, czego skutkiem jest powstawanie zbyt wygładzonych obrazów, pozbawionych detali. Wykorzystanie modeli dyfuzyjnych próbuje rozwiązać te problemy. Ponieważ są to metody generatywne, zamiast uśredniać możliwe rozwiązania, odtwarzają one prawdopodobne szczegóły. Przekłada się to na ostrzejsze i bardziej naturalne rezultaty. Poprawa ta ma jednak swój koszt, VSR oparte na dyfuzji jest wymagające pod względem obliczeniowym, pamięciowym oraz czasowym. Iteracyjny proces odsumowania i kwadratowa złożoność uwagi w odniesieniu do tokenów czasoprzestrzennych utrudnia praktyczne wykorzystanie.

Jednokrokowe modele uzyskiwane w wyniku destylacji wiedzy są częściową odpowiedzią na ten problem. Reprezentatywnym przykładem jest FlashVSR [1]. Twórcy modelu połączyli destylację do modelu jednokrokowego z blokowo-rzadką uwagą, aby zbliżyć się do przetwarzania w czasie rzeczywistym. Destylacja eliminuje koszt wielokrotnego odsumowania, ale nie redukuje narzutu pamięciowego w pojedynczej inferencji, który determinuje, czy model może zostać uruchomiony na danym urządzeniu.

Stwarza to istotną barierę, ponieważ dostępne modele, takie jak FlashVSR, zakładają wykorzystanie akceleratorów klasy serwerowej. Autorzy tego modelu wskazują, że szczytowe zużycie pamięci osiąga 11,13 GB przy 101 klatkach o rozdzielczości wyjściowej 768×1408 [1]. Oznacza to, że sekwencja wejściowa miała wymiary zaledwie 192×352 przy powiększeniu $\times 4$, czyli parametry znacząco odbiegające od rozdzielczości typowych nagrań. Konsumenckie karty graficzne oferują zazwyczaj od 8 do 12 GB pamięci VRAM; sprzęt referencyjny przyjęty w pracy, czyli NVIDIA RTX 3080, zapewnia 10 GB. Zapotrzebowanie na pamięć przekracza dostępny budżet nawet w tak korzystnym scenariuszu, a deficyt ten rośnie wraz ze wzrostem rozdzielczości wejściowej. Rodzi to pytanie, czy model tej klasy da się uruchomić w budżecie 10 GB VRAM i jakimi kompromisami w zakresie jakości rekonstrukcji oraz czasu inferencji się to wiąże.

1.2 Cel i zakres pracy

Celem pracy jest umożliwienie inferencji jednokrokowego, dyfuzyjnego modelu superrozdzielczości wideo na karcie graficznej wyposażonej w 10 GB pamięci VRAM, przy zachowaniu akceptowalnych jakości rekonstrukcji i czasu przetwarzania. Jako model bazowy przyjęto FlashVSR [1].

Realizacja tego celu wymagała refaktoryzacji kodu referencyjnej implementacji do postaci modularnego pakietu oraz zaimplementowania trzech konfigurowalnych technik redukujących wymagania sprzętowe: wymiennych wariantów mechanizmu uwagi, kwantyzacji, oraz kafelkowania przestrzennego i czasowego. Opracowano również metodykę pomiarową obejmującą czas inferencji, szczytowe zużycie pamięci i jakość rekonstrukcji. Umożliwiło to porównanie uzyskanych konfiguracji między sobą oraz z konfiguracją referencyjną.

Zakres pracy ogranicza się do fazy inferencji. Nie przeprowadzono treningu ani dostrajania, a we wszystkich eksperymentach wykorzystano publicznie udostępnione wagi. Wkład pracy ma charakter inżynieryjno-eksperymentalny i polega na adaptacji istniejącego modelu do środowiska o ograniczonych zasobach i zbadaniu zależności między jakością rekonstrukcji, czasem inferencji a zużyciem pamięci.

1.3 Struktura pracy

TODO: Opisać strukturę pracy.

2 Podstawy teoretyczne

2.1 Superrozdzielczość wideo

Superrozdzielczość wideo to zadanie z zakresu widzenia komputerowego, którego celem jest generowanie materiałów wideo o wysokiej rozdzielczości (ang. *high-resolution*, HR) i ulepszonej jakości wizualnej na podstawie wejściowych sekwencji o niskiej rozdzielczości (ang. *low-resolution*, LR). Podstawową różnicą między VSR, a superrozdzielczością obrazów (ang. *Single Image Super-Resolution*, SISR) jest obecność w wideo dodatkowego wymiaru czasowego. SISR bazuje wyłącznie na informacji przestrzennej z pojedynczego obrazu, natomiast VSR wykorzystuje dodatkowo silne korelacje między kolejnymi klatkami. Bezpośrednie zastosowanie metod SISR do pojedynczych klatek wideo nie pozwala na uchwycenie tych zależności czasowych [2].

2.1.1 Sformułowanie problemu

Problem superrozdzielczości wideo jest zdefiniowany jako zadanie odwrotne, w którym dążymy do odzyskania sekwencji HR na podstawie obserwowanej sekwencji LR. Proces powstawania materiału LR jest zazwyczaj modelowany jako złożenie degradacji fizycznych i cyfrowych.

Ogólny model degradacji dla i -tej klatki wideo można zapisać jako funkcję zależną od klatki docelowej $\hat{I}_i$ oraz jej sąsiedztwa czasowego [3]:

$$I_i = \phi\left(\hat{I}_i, \{\hat{I}_j\}_{j=i-N}^{i+N}; \theta_\alpha\right), \quad (1)$$

gdzie I_i oznacza obserwowaną klatkę o niskiej rozdzielczości, N oznacza promień czasowy (zakres sąsiednich klatek), a θ_α reprezentuje parametry procesu degradacji (np. szum, rozmycie).

Celem modelu VSR jest znalezienie funkcji odwzorowującej f_{VSR} , sparametryzowanej przez wagi $\theta_{f_{\text{VSR}}}$, która estymuje klatkę wysokiej rozdzielczości $\hat{I}_{\text{SR}_i}$ na podstawie sekwencji klatek wejściowych LR [3]:

$$\hat{I}_{\text{SR}_i} = f_{\text{VSR}}\left(I_i, \{I_j\}_{j=i-N}^{i+N}; \theta_{f_{\text{VSR}}}\right), \quad (2)$$

Powyższe klasyczne sformułowania zakładają uproszczone, deterministyczne zniekształcenia, które nie odzwierciedlają warunków rzeczywistych. W praktyce proces utraty jakości wymaga zaawansowanych modeli degradacji, które łączą losowe rozmycia, szum oraz zmianę rozmiaru i artefakty kompresji [4].

2.1.2 Spójność czasowa

Spójność czasowa w kontekście superrozdzielczości wideo polega na utrzymaniu ciągłości, płynności oraz braku zauważalnych zniekształceń i migotania między kolejnymi klatkami wygenerowanej sekwencji HR [2], [3]. Bezpośrednie zastosowanie metod SISR do poszczególnych klatek pomija zależności czasowe, co prowadzi do niestabilności detali i artefaktów wizualnych. W modelach głębokiego uczenia spójność tę realizuje się poprzez techniki wyrównywania klatek i kompensacji ruchu (ang. *motion estimation and motion compensation*, MEMC), konwolucje 3D, moduły rekurencyjne (RNN) propagujące kontekst czasowy oraz mechanizmy uwagi [2]. Choć metody te poprawiają jakość generowanych sekwencji, analiza wielu klatek znacznie zwiększa

złożoność obliczeniową i pamięciową. W warunkach rzeczywistych stwarza to ryzyko akumulacji i przenoszenia błędów między klatkami [4].

2.2 Modele dyfuzyjne

Modele dyfuzyjne (ang. *Denoising Diffusion Probabilistic Models*, DDPMs) to klasa modeli generatywnych, która wykorzystuje dwa podstawowe łańcuchy Markowa: w przód (ang. *forward chain*), który stopniowo zniekształca dane poprzez dodawanie szumu, oraz w tył (ang. *reverse chain*), przekształcający szum spowrotem w ustrukturyzowane dane.

2.2.1. Proces zaszumiania i odszumiania 2.2.2. Flow matching 2.2.3. Dyfuzja w przestrzeni latentnej

2.3 Diffusion Transformer i mechanizm uwagi

2.3.1. Uwaga skalowana iloczynem skalarnym 2.3.2. FlashAttention 2.3.3. SageAttention 2.3.4. Rzadkość strukturalna i maski blokowe

2.4 Kwantyzacja sieci neuronowych

2.4.1. Kwantyzacja wag a kwantyzacja aktywacji 2.4.2. Tryby weight-only i dynamic 2.4.3. Wsparcie INT8 na architekturze Ampere

2.5 Kafelkowanie przestrzenne i czasowe

2.6 Metryki oceny jakości wideo

2.6.1. Metryki pełnoreferencyjne 2.6.2. Metryki bezreferencyjne 2.6.3. Ograniczenia metryk dla modeli generatywnych

3 Przegląd istniejących rozwiązań

4 Wybór rozwiązań do implementacji

5 Narzędzia, środowisko i projekt systemu

6 Implementacja

7 Metodyka badań i testy

8 Wyniki i ich omówienie

9 Podsumowanie i wnioski

Bibliografia

- [1] J. Zhuang *et al.*, „FlashVSR: Towards Real-Time Diffusion-Based Streaming Video Super-Resolution”, *ArXiv*, 2025.
- [2] A. A. Baniya, T.-K. Lee, P. W. Eklund, i S. Aryal, „A Survey of Deep Learning Video Super-Resolution”, *IEEE Transactions on Emerging Topics in Computational Intelligence*, t. 8, nr 4, s. 2655–2676, sie. 2024, doi: [10.1109/tetci.2024.3398015](https://doi.org/10.1109/tetci.2024.3398015).
- [3] H. Liu *et al.*, „Video Super Resolution Based on Deep Learning: A Comprehensive Survey”. [Online]. Dostępne na: <https://arxiv.org/abs/2007.12928>
- [4] K. C. K. Chan, S. Zhou, X. Xu, i C. C. Loy, „Investigating Tradeoffs in Real-World Video Super-Resolution”. [Online]. Dostępne na: <https://arxiv.org/abs/2111.12704>

Wykaz symboli i skrótów

GOAT – greatest of all time

KDE Community: An international team developing and distributing Open Source software.

OIDC – **OpenID Connect**: OpenID is an open standard and decentralized authentication protocol promoted by the non-profit [OpenID Foundation](#).

WUT – Warsaw University of Technology

Spis rysunków

Spis tabel

TODOs

□ TODO: Napisać streszczenie w języku polskim.	2
□ TODO: Write the abstract in English.	3
□ TODO: Opisać strukturę pracy.	6